BÀI 2: SỰ TƯƠNG ĐỒNG VÀ CÁC KHOẢNG CÁCH

I. Mục tiêu:

Sau khi thực hành xong, sinh viên nắm được:

- Khoảng cách giữa các điểm trong tập dữ liệu số sử dụng chuẩn L_p với $p = 1, 2, \infty$.
- Sự tương đồng của các điểm trong tập dữ liệu phân loại sử dụng: độ đo Overlap và độ đo tần suất xuất hiện ngược.

II. Tóm tắt lý thuyết:

1. Khoảng cách giữa các điểm trong tập dữ liệu số:

Cho 2 điểm dữ liệu $\overline{X} = (x_1 \dots x_n)$ và $\overline{Y} = (y_1 \dots y_n)$, khoảng cách giữa 2 điểm dữ liệu này dùng chuẩn L_p được xác định như sau:

$$Dist(\overline{X}, \overline{Y}) = \left(\sum_{i=1}^{n} |x_i - y_i|^p \right)^{1/p}$$

Các trường hợp đặc biệt của chuẩn L_p là

- $p = 1$ (Manhattan)
$$Dist(\overline{X}, \overline{Y}) = \left(\sum_{i=1}^{n} |x_i - y_i| \right)$$
- $p = 2$ (Euclidean)
$$Dist(\overline{X}, \overline{Y}) = \left(\sum_{i=1}^{n} |x_i - y_i|^2 \right)^{1/2}$$
- $p = \infty$
$$Dist(\overline{X}, \overline{Y}) = \max_{1 \leqslant i \leqslant n} |x_i - y_i|$$

Ví dụ: Cho x, y là tọa độ của 4 điểm như sau:

	x	y
p_1	3	1
p_2	1	2
p_3	2	0
p_4	2	3

Ta có các ma trận khoảng cách như sau:

- Với $p = 1$, ta có

$$Dist(p_1, p_2) = |3-1| + |1-2| = 2 + 1 = 3$$

$$Dist(p_1, p_3) = |3-2| + |1-0| = 1 + 1 = 2$$

$$Dist(p_1, p_4) = |3-2| + |1-3| = 1 + 2 = 3$$

$$Dist(p_2, p_3) = |1-2| + |2-0| = 1 + 2 = 3$$

$$Dist(p_2, p_4) = |1-2| + |2-3| = 1 + 1 = 2$$

$$Dist(p_3, p_4) = |2-2| + |0-3| = 0 + 3 = 3$$

Khi đó, ma trận khoảng cách L_1 giữa 4 điểm này là

	p_1	p_2	p_3	p_4
p_1	0	3	2	3
p_2	3	0	3	2
p_3	2	3	0	3
p_4	3	2	3	0

- Với $p = 2$, ta có

$$Dist(p_1, p_2) = (|3-1|^2 + |1-2|^2)^{1/2} = \sqrt{5}$$

$$Dist(p_1, p_3) = (|3-2|^2 + |1-0|^2)^{1/2} = \sqrt{2}$$

$$Dist(p_1, p_4) = (|3-2|^2 + |1-3|^2)^{1/2} = \sqrt{5}$$

$$Dist(p_2, p_3) = (|1-2|^2 + |2-0|^2)^{1/2} = \sqrt{5}$$

$$Dist(p_2, p_4) = (|1-2|^2 + |2-3|^2)^{1/2} = \sqrt{2}$$

$$Dist(p_3, p_4) = (|2-2|^2 + |0-3|^2)^{1/2} = 3$$

Khi đó, ma trận khoảng cách L_2 (Euclide) giữa 4 điểm này là

	p_1	p_2	p_3	p_4
p_1	0	$\sqrt{5}$	$\sqrt{2}$	$\sqrt{5}$
p_2	$\sqrt{5}$	0	$\sqrt{5}$	$\sqrt{2}$
p_3	$\sqrt{2}$	$\sqrt{5}$	0	3
p_4	$\sqrt{5}$	$\sqrt{2}$	3	0

- Với $p = \infty$, ta có

$$Dist(p_1, p_2) = \max(|3-1|, |1-2|) = \max(2, 1) = 2$$

$$Dist(p_1, p_3) = \max(|3-2|, |1-0|) = \max(1, 1) = 1$$

$$Dist(p_1, p_4) = \max(|3-2|, |1-3|) = \max(1, 2) = 2$$

$$Dist(p_2, p_3) = \max(|1-2|, |2-0|) = \max(1, 2) = 2$$

$$Dist(p_2, p_4) = \max(|1-2|, |2-3|) = \max(1, 1) = 1$$

$$Dist(p_3, p_4) = \max(|2-2|, |0-3|) = \max(0, 3) = 3$$

Khi đó, ma trận khoảng cách L_∞ giữa 4 điểm này là

	p_1	p_2	p_3	p_4
p_1	0	2	1	2
p_2	2	0	2	1
p_3	1	2	0	3
p_4	2	1	3	0

2. Sự tương đồng giữa các điểm trong tập dữ liệu phân loại:

Cho D là một tập dữ liệu phân loại chứa N đối tượng xác định trên tập d thuộc tính phân loại mà A_i là thuộc tính thứ i. $\mathcal{A}_i$ là thuộc tính A_i lấy n_i giá trị trong tập D.
Xét 2 bản ghi $\overline{X} = (x_1 \dots x_d)$ và $\overline{Y} = (y_1 \dots y_d)$, sự tương đồng đơn giản nhất giữa 2 bản ghi này được xác định như sau

$$Sim(\overline{X}, \overline{Y}) = \sum_{i=1}^{d} w_i S(x_i, y_i)$$

a. Độ đo Overlap: $S(x_i, y_i)$ là sự tương đồng giữa các giá trị thuộc tính x_i, y_i

$$S(x_i, y_i) = \begin{cases} 1 & \text{nếu } \ x_i = y_i \\ 0 & \text{ngược lại} \end{cases}$$

và $w_i = \dfrac{1}{d}$ với $i = 1 \dots, d$.
Ví dụ: Cho $\overline{X} = (tcp, http, SF, normal.)$ và $\overline{Y} = (tcp, http, S2, normal.)$.

Ta có,

$$S(x_1, y_1) = S(tcp, tcp) = 1$$

$$S(x_2, y_2) = S(http, http) = 1$$

$$S(x_3, y_3) = S(SF, S2) = 0$$

$$S(x_4, y_4) = S(normal., normal.) = 1$$

$$w_i = \frac{1}{4},\ i = 1, \ldots, 4.$$

Khi đó, sự tương đồng giữa $\overline{X}$ và $\overline{Y}$ là

$$Sim(\overline{X}, \overline{Y}) = \frac{1}{4} \times 1 + \frac{1}{4} \times 1 + \frac{1}{4} \times 0 + \frac{1}{4} \times 1 = \frac{3}{4}$$

b. Độ đo tần suất xuất hiện ngược: Cho $f_i(x)$ là số lần thuộc tính A_i lấy giá trị x trong tập dữ liệu D. Nếu $x \notin \mathcal{A}_i$ thì $f_i(x) = 0$.

$$S(x_i, y_i) = \begin{cases} 1 & \text{nếu } \ x_i = y_i \\ \dfrac{1}{1 + \log f_i(x_i) \times \log f_i(y_i)} & \text{ngược lại} \end{cases}$$

và $w_i = \dfrac{1}{d}$ với $i = 1 \ldots, d$.

Ví dụ: Cho tập D

	1	2	3	4
1	tcp	http	SF	normal.
2	tcp	http	S2	normal.
3	tcp	http	S1	normal.
4	tcp	smtp	SF	normal.
5	udp	domain_u	SF	normal.
6	tcp	bgp	S2	neptune.
7	tcp	S2	REJ	neptune.
8	tcp	smtp	SF	neptune.
9	tcp	other	RSTO	neptune.
10	tcp	telnet	RSTO	buffer_overflow.

Xét $\overline{X} = (tcp, http, SF, normal.)$ và $\overline{Y} = (tcp, http, S2, normal.)$.

Ta có

$$
\begin{aligned}
S(x_1, y_1) &= S(tcp, tcp) = 1 \\
S(x_2, y_2) &= S(http, http) = 1 \\
S(x_3, y_3) &= S(SF, S2) = \frac{1}{1 + \log f_3(x_3) \times \log f_3(y_3)} \\
&= \frac{1}{1 + \log f_3(SF) \times \log f_3(S2)} = \frac{1}{1 + \log(4) \times \log(2)} = 0.51 \\
S(x_4, y_4) &= S(normal., normal.) = 1 \\
w_i &= \frac{1}{4},\ i = 1, \ldots, 4.
\end{aligned}
$$

Khi đó, sự tương đồng giữa dòng 1 và dòng 2 là:

$$
Sim(\overline{X}, \overline{Y}) = \frac{1}{4} \times 1 + \frac{1}{4} \times 1 + \frac{1}{4} \times 0.51 + \frac{1}{4} \times 1 = 0.8775.
$$

III. Nội dung thực hành:

1. Khoảng cách giữa các điểm trong dữ liệu số

- Download the Ionosphere data set from the UCI Machine Learning Repository (`https://archive.ics.uci.edu/dataset/52/ionosphere`)

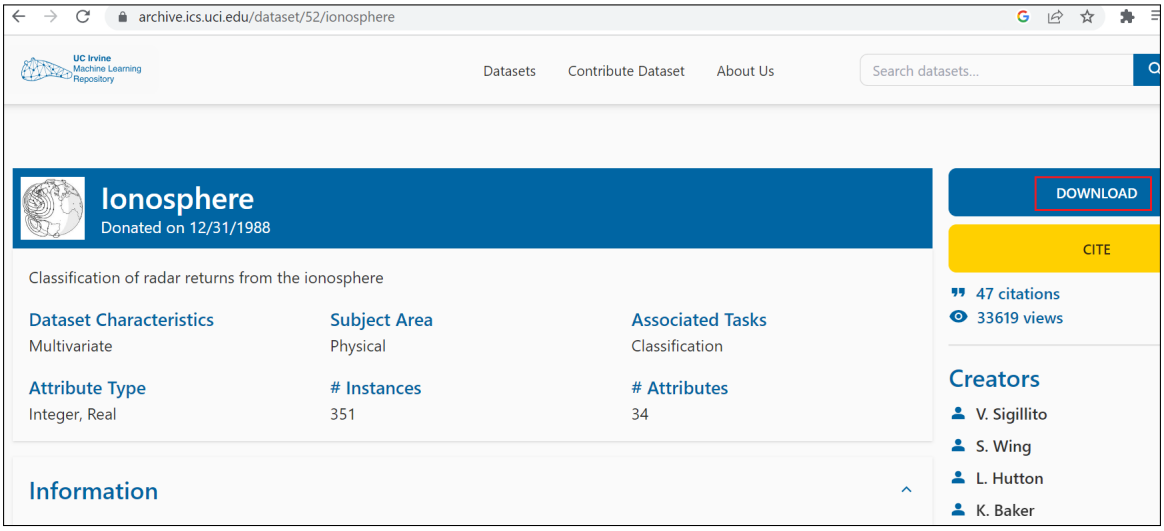

- Đọc dữ liệu từ file "ionosphere.data":

```
import pandas as pd
import numpy as np

df = pd.read_csv('D:\\Huynh\\DataMining_Lab\\data\\tuan2\\ionosphere.data', header=None)
print(df)
```

```
     0   1        2        3        4   ...       30       31       32       33  34
0    1   0  0.99539 -0.05889  0.85243  ...  0.42267 -0.54487  0.18641 -0.45300   g
1    1   0  1.00000 -0.18829  0.93035  ... -0.16626 -0.06288 -0.13738 -0.02447   b
2    1   0  1.00000 -0.03365  1.00000  ...  0.60436 -0.24180  0.56045 -0.38238   g
3    1   0  1.00000 -0.45161  1.00000  ...  0.25682  1.00000 -0.32382  1.00000   b
4    1   0  1.00000 -0.02401  0.94140  ... -0.05707 -0.59573 -0.04608 -0.65697   g
..  ..  ..      ...      ...      ...  ...      ...      ...      ...      ...  ..
346  1   0  0.83508  0.08298  0.73739  ...  0.86660 -0.10714  0.90546 -0.04307   g
347  1   0  0.95113  0.00419  0.95183  ...  0.94066 -0.00035  0.91483  0.04712   g
348  1   0  0.94701 -0.00034  0.93207  ...  0.92459  0.00442  0.92697 -0.00577   g
349  1   0  0.90608 -0.01657  0.98122  ...  0.96022 -0.03757  0.87403 -0.16243   g
350  1   0  0.84710  0.13533  0.73638  ...  0.75747 -0.06678  0.85764 -0.06151   g

[351 rows x 35 columns]
```

- Xử lý dữ liệu (bỏ cột cuối):

```
df.pop(df.columns[-1])
print(df)
```

```
     0   1        2        3   ...       30       31       32       33
0    1   0  0.99539 -0.05889  ...  0.42267 -0.54487  0.18641 -0.45300
1    1   0  1.00000 -0.18829  ... -0.16626 -0.06288 -0.13738 -0.02447
2    1   0  1.00000 -0.03365  ...  0.60436 -0.24180  0.56045 -0.38238
3    1   0  1.00000 -0.45161  ...  0.25682  1.00000 -0.32382  1.00000
4    1   0  1.00000 -0.02401  ... -0.05707 -0.59573 -0.04608 -0.65697
..  ..  ..      ...      ...  ...      ...      ...      ...      ...
346  1   0  0.83508  0.08298  ...  0.86660 -0.10714  0.90546 -0.04307
347  1   0  0.95113  0.00419  ...  0.94066 -0.00035  0.91483  0.04712
348  1   0  0.94701 -0.00034  ...  0.92459  0.00442  0.92697 -0.00577
349  1   0  0.90608 -0.01657  ...  0.96022 -0.03757  0.87403 -0.16243
350  1   0  0.84710  0.13533  ...  0.75747 -0.06678  0.85764 -0.06151

[351 rows x 34 columns]
```

- Khởi tạo các điểm point1, point2, point3 tương ứng là dòng 0, 1, 2 của array và tính chuẩn $p = 1, 2, \infty$:

```
#array
array = df.values
print(array)

point1 = array[0,:]
point2=array[1,:]
point3 = array[2,:]
#p=1
dist01_2 = np.linalg.norm(point1 - point2,1)
dist01_3 = np.linalg.norm(point1 - point3,1)
#p=2
dist1_2 = np.linalg.norm(point1 - point2)
dist1_3 = np.linalg.norm(point1 - point3)
#p=inf
dist11_2 = np.linalg.norm(point1 - point2,np.inf)
dist11_3 = np.linalg.norm(point1 - point3,np.inf)
#print results
print(dist1_2)
print(dist1_3)
print(dist01_2)
print(dist01_3)
print(dist11_2)
print(dist11_3)
```

```
[[ 1.        0.        0.99539 ... -0.54487  0.18641 -0.453  ]
 [ 1.        0.        1.      ... -0.06288 -0.13738 -0.02447]
 [ 1.        0.        1.      ... -0.2418   0.56045 -0.38238]
 ...
 [ 1.        0.        0.94701 ...  0.00442  0.92697 -0.00577]
 [ 1.        0.        0.90608 ... -0.03757  0.87403 -0.16243]
 [ 1.        0.        0.8471  ... -0.06678  0.85764 -0.06151]]
```

```
2.7763589251571923
1.1697276018372824
13.080950000000001
5.35971
1.12221
0.45772
```

2. Độ đo tương đồng giữa các điểm trong tập dữ liệu phân loại

- Download the KDD Cup Network Intrusion Data Set for the UCI Machine Learning Repository

  (`https://archive.ics.uci.edu/dataset/130/kdd+cup+1999+data`)

- Giải nén file "kddcup.data.gz" và đọc file "kddcup.data.conected"

```
import pandas as pd
import numpy as np
from sklearn.preprocessing import KBinsDiscretizer
from sklearn.preprocessing import StandardScaler

df = pd.read_csv('D:\\Huynh\\DataMining_Lab\\data\\tuan2\\kddcup.data\\kddcup.data.corrected',
                 header = None)
print(df)
```

```
         0    1     2   3    4      5   ...    36   37    38   39   40        41
0        0  tcp  http  SF  215  45076  ...  0.00  0.0  0.00  0.0  0.0  normal.
1        0  tcp  http  SF  162   4528  ...  0.00  0.0  0.00  0.0  0.0  normal.
2        0  tcp  http  SF  236   1228  ...  0.00  0.0  0.00  0.0  0.0  normal.
3        0  tcp  http  SF  233   2032  ...  0.00  0.0  0.00  0.0  0.0  normal.
4        0  tcp  http  SF  239    486  ...  0.00  0.0  0.00  0.0  0.0  normal.
...     ..  ...   ...  ..  ...    ...  ...   ...  ...   ...  ...  ...      ...
4898426  0  tcp  http  SF  212   2288  ...  0.05  0.0  0.01  0.0  0.0  normal.
4898427  0  tcp  http  SF  219    236  ...  0.05  0.0  0.01  0.0  0.0  normal.
4898428  0  tcp  http  SF  218   3610  ...  0.05  0.0  0.01  0.0  0.0  normal.
4898429  0  tcp  http  SF  219   1234  ...  0.05  0.0  0.01  0.0  0.0  normal.
4898430  0  tcp  http  SF  219   1098  ...  0.05  0.0  0.01  0.0  0.0  normal.

[4898431 rows x 42 columns]
```

- Chọn các cột có thuộc tính là 'object' (cột 1, 2, 3 và 41)

```
categorical_columns = df.select_dtypes(include=['object']).columns
print("Categorical attributes:", categorical_columns)
categorical_data = df[categorical_columns]
print("Categorical Data:\n", categorical_data)
```

```
Categorical attributes: Int64Index([1, 2, 3, 41], dtype='int64')
Categorical Data:
           1     2   3        41
0        tcp  http  SF  normal.
1        tcp  http  SF  normal.
2        tcp  http  SF  normal.
3        tcp  http  SF  normal.
4        tcp  http  SF  normal.
...      ...   ...  ..      ...
4898426  tcp  http  SF  normal.
4898427  tcp  http  SF  normal.
4898428  tcp  http  SF  normal.
4898429  tcp  http  SF  normal.
4898430  tcp  http  SF  normal.

[4898431 rows x 4 columns]
```

- Kiểm tra các giá trị giống nhau và loại bỏ những dòng giống nhau này

```
#- Kiểm tra giá trị giống nhau
print("So luong dong giong nhau: ",categorical_data.duplicated().sum())

##loại bỏ các các dòng giống nhau
df1=categorical_data.drop_duplicates()
print("Du lieu sau khi xoa nhung dong giong nhau: \n",df1)
```

```
So luong dong giong nhau:  4897822
Du lieu sau khi xoa nhung dong giong nhau:
           1         2     3                  41
0        tcp      http    SF            normal.
1288     tcp      http    S2            normal.
1484     tcp      http    S1            normal.
2062     tcp      smtp    SF            normal.
2067     udp  domain_u    SF            normal.
...      ...       ...   ...                ...
4574130  tcp       bgp   REJ           neptune.
4575586  tcp    Z39_50   REJ           neptune.
4578870  tcp      smtp    SF           neptune.
4579297  tcp     other  RSTO           neptune.
4810949  tcp    telnet  RSTO  buffer_overflow.

[609 rows x 4 columns]
```

3. Yêu cầu:

- Viết hàm tính các chuẩn $p = 1, 2, \infty$ cho 50 dòng đầu tiên của array trong mục 1.
- Tính các láng giềng gần nhất ở mục 2 sử dụng độ đo Overlap và độ đo tần suất xuất hiện ngược cho 100 dòng đầu tiên.
- Viết file báo cáo.