



01

Giới thiệu quá trình khai phá dữ liệu

02

Kiến thức chuẩn bị liên quan

03

Các loại dữ liệu thông dụng

04

Các bước chuẩn bị dữ liệu  
(Data Preparation)

05

Khoảng cách và độ tương đồng  
(Similarity and Distances)

# NỘI DUNG MÔN HỌC

06

Khai thác mô hình liên kết  
(Association Pattern Mining)

07

Phân tích gom cụm  
(Clustering Analysis)

08

Phân tích kỳ dị  
(Outlier Analysis)

09

Phân loại dữ liệu  
(Data Classification)



# INTRODUCTION

- **Khai thác dữ liệu** là ngành nghiên cứu khoa học liên quan đến việc: thu thập, làm sạch, xử lý, phân tích, đạt được những thông tin hữu ích từ dữ liệu thu thập.
- Có rất nhiều biến thể liên quan đến khai thác dữ liệu, tùy thuộc vào:
  - Dạng bài toán
  - Các ứng dụng
  - Công thức
  - Cách thức biểu diễn dữ liệu gặp phải trong các ứng dụng thực tế



# INTRODUCTION

Do đó, việc “khai thác dữ liệu” là một thuật ngữ có tính phổ quát cao và được sử dụng để mô tả các khía cạnh khác nhau của quá trình xử lý dữ liệu.



# INTRODUCTION

Ngày nay, dữ liệu thu thập được là vô cùng lớn từ các hệ thống ở các công ty và các tập đoàn trên thế giới.

01

## World Wide Web:

- The indexed Web contains billions of documents, while the invisible Web is even larger.
- User interactions generate data, such as Web access logs and customer behavior profiles.
- The linked structure of the Web is called the Web graph and is a form of data.
- Different types of Web data have valuable applications:
  - Mining Web documents and link structures to identify topic associations.
  - Analyzing user access logs to detect frequent or unusual behavior patterns.

02

## Financial interactions:

Most common transactions of everyday life, such as using an automated teller machine (ATM) card or a credit card, can create data in an automated way. Such transactions can be mined for many useful insights such as fraud or other unusual activity.

03

## User interactions

Many forms of user interactions create large volumes of data. For example, the use of a telephone typically creates a record at the telecommunication company with details about the duration and destination of the call. Many phone companies routinely analyze such data to determine relevant patterns of behavior that can be used to make decisions about network capacity, promotions, pricing, or customer targeting.

04


## Sensor technologies and the Internet of Things:

A recent trend is the development of low-cost wearable sensors, smartphones, and other smart devices that can communicate with one another. By one estimate, the number of such devices exceeded the number of people on the planet in 2008. The implications of such massive data collection are significant for mining algorithm.



# INTRODUCTION

Dữ liệu thô từ các nguồn dữ liệu khác nhau có thể là các format tùy ý, không có cấu trúc hoặc có cấu trúc. Thậm chí, có một số trường hợp dữ liệu thô có dạng bán cấu trúc hoặc ở định dạng không phù hợp ngay lập tức để có thể xử lý tự động hiệu quả



Với nguồn dữ liệu dồi dào từ khách hàng và các hệ thống/sản phẩm của công ty, nhu cầu xây dựng các hệ thống phân tích và mô tả dữ liệu là vô cùng to lớn.

# INTRODUCTION

Ví dụ: Dữ liệu được thu thập thủ công có thể được lấy từ các nguồn không đồng nhất ở các định dạng khác nhau nhưng bằng cách nào đó cần phải được xử lý bởi một chương trình máy tính tự động để có được thông tin chi tiết.

Các nhà phân tích khai thác dữ liệu sẽ sử dụng một hệ thống xử lý, trong đó, các nguyên dữ liệu đầu vào sẽ được:

- Thu thập
- Làm sạch
- Chuyển đổi thành một định dạng tiêu chuẩn hóa



# INTRODUCTION

Dữ liệu có thể có nhiều loại định dạng hoặc các kiểu khác nhau. Các loại dữ liệu ở đây có thể là:

- Định lượng (Ví dụ: Tuổi)
- Phân loại (Ví dụ: Giới tính)
- Văn bản
- Không gian, thời gian
- Biểu đồ



Mặc dù, cho đến nay phần lớn các dạng dữ liệu phổ biến là đa chiều, các loại dữ liệu có cấu trúc phức tạp hơn dần dần có tỷ lệ ngày càng tăng so với trước đây.



# DATA MINING PROCESS



Quá trình khai thác dữ liệu là một quá trình bao gồm nhiều giai đoạn, chẳng hạn như làm sạch dữ liệu, trích xuất tính năng, và thiết kế thuật toán.





Figure 1.1: The data processing pipeline



# DATA PREPROCESSING

- Đây là giai đoạn quan trọng nhất trong quá trình xử lý dữ liệu.
- Giai đoạn này nối tiếp sau việc thu thập dữ liệu và có thể được chia thành các bước sau.
  - Trích xuất tính năng
  - Làm sạch dữ liệu
  - Chọn lọc tính năng và biến đổi



# DATA PREPROCESSING

## 01 Feature extraction

An analyst may be confronted with vast volumes of raw documents, system logs, or commercial transactions with little guidance on how these raw data should be transformed into meaningful database features for processing. This phase is highly dependent on the analyst to be able to abstract out the features that are most relevant to a particular application. For example, in a credit-card fraud detection application, the amount of charge, the repeat frequency, and the location are often good indicators of fraud. However, many other features may be poorer indicators of fraud. Therefore, extracting the right features is often a skill that requires an understanding of the specific application domain at hand.



# DATA PREPROCESSING

## 02 Data cleaning

The extracted data may have erroneous or missing entries. Therefore, some records may need to be dropped, or missing entries may need to be estimated. Inconsistencies may need to be removed



# DATA PREPROCESSING

## 03 Feature selection and transformation:

When the data are very high dimensional, many data mining algorithms do not work effectively. Furthermore, many of the high-dimensional features are noisy and may add errors to the data mining process. Therefore, a variety of methods are used to either remove irrelevant features or transform the current set of features to a new data space that is more amenable for analysis. Another related aspect is data *transformation*, where a data set with a particular set of attributes may be transformed into a data set with another set of attributes of the same or a different type. For example, an attribute, such as age, may be partitioned into ranges to create discrete values for analytical convenience.







# GIAI ĐOẠN PHÂN TÍCH



Việc mỗi ứng dụng khai phá dữ liệu đều khác nhau khiến việc tạo các kỹ thuật tổng quát có thể tái sử dụng rất khó.



Tuy nhiên, vẫn có nhiều thiết lập khai phá dữ liệu có thể được tái sử dụng với các hoàn cảnh ứng dụng khác nhau.



Việc sử dụng này phụ thuộc vào kỹ năng và kinh nghiệm.