

KHAI PHÁ DỮ LIỆU

Tuần 08

PGS. TS. Nguyễn Thanh Bình

Khoa Toán - Tin học, Trường Đại học Khoa học Tự nhiên
Đại học Quốc gia TP. Hồ Chí Minh

Nội dung

- 1 Các thuật toán dựa theo đại diện
 - Thuật toán k -Means
 - Thuật toán kernel k -Means
 - Thuật toán k -Medoids
- 2 Các thuật toán gom cụm phân tầng
 - Phương pháp từ dưới lên (agglomerative/kết tụ)
 - Phương pháp từ trên xuống (divisive)
- 3 Các thuật toán dựa theo mô hình xác suất
- 4 Các thuật toán dựa theo lưới và dựa theo mật độ
 - Các thuật toán dựa theo lưới
 - Các thuật toán dựa theo mật độ
- 5 Các thuật toán dựa theo đồ thị

Nội dung

- 1 Các thuật toán dựa theo đại diện
 - Thuật toán k -Means
 - Thuật toán kernel k -Means
 - Thuật toán k -Medoids
- 2 Các thuật toán gom cụm phân tầng
 - Phương pháp từ dưới lên (agglomerative/kết tụ)
 - Phương pháp từ trên xuống (divisive)
- 3 Các thuật toán dựa theo mô hình xác suất
- 4 Các thuật toán dựa theo lưới và dựa theo mật độ
 - Các thuật toán dựa theo lưới
 - Các thuật toán dựa theo mật độ
- 5 Các thuật toán dựa theo đồ thị

Các thuật toán dựa theo đại diện

- Các thuật toán dựa theo đại diện dựa trực tiếp vào khái niệm khoảng cách (hoặc sự tương đồng) để gom nhóm dữ liệu.
- Trong các thuật toán này, các nhóm được tạo trong một lần và không có quan hệ phân tầng với các nhóm.
- Giả sử có k cụm. Xét tập dữ liệu $\mathcal{D}$ gồm n điểm dữ liệu được ký hiệu $\overline{X}_1 \dots \overline{X}_n$ trong không gian d chiều. Mục tiêu xác định k đại diện $\overline{Y}_1 \dots \overline{Y}_k$ sao cho tối thiểu hàm mục tiêu O :

$$O = \sum_{i=1}^n [\min_j \text{Dist}(\overline{X}_i, \overline{Y}_j)]$$


Các thuật toán dựa theo đại diện

Các bài toán tối ưu này thường được giải bằng phương pháp lặp với mỗi bước lặp có 2 bước con:

- *Bước gán*: gán mỗi điểm dữ liệu vào đại diện gần nhất của nó trong tập S bằng cách sử dụng hàm đo khoảng cách $Dist(.,.)$. Các cụm tương ứng được ký hiệu là $C_1 \dots C_k$.
- *Bước tối ưu*: Xác định $\overline{Y}_j$ cho mỗi cụm C_j sao cho tối thiểu hàm mục tiêu cục bộ :



$$\sum_{\overline{X}_i \in C_j} [Dist(\overline{X}_i, \overline{Y}_j)]$$

Các thuật toán dựa theo đại diện





Hình 1: Illustration of k -representative algorithm with random initialization (1)

Các thuật toán dựa theo đại diện



Hình 2: Illustration of k -representative algorithm with random initialization (2)

Các thuật toán dựa theo đại diện



Hình 3: Illustration of k -representative algorithm with random initialization (3)

Thuật toán k -Means

- Trong các thuật toán k -Means, tổng bình phương khoảng cách từ các điểm dữ liệu đến đại diện gần nhất được dùng cho hàm mục tiêu của bài toán tối ưu.

$$Dist(\overline{X}_i, \overline{Y}_j) = \|\overline{X}_i - \overline{Y}_j\|_2^2$$

- Ngoài ra, chúng ta còn có biến thể khác sử dụng khoảng cách Mahalanobis

$$Dist(\overline{X}_i, \overline{Y}_j) = (\overline{X}_i - \overline{Y}_j) \sum_j^{-1} (\overline{X}_i - \overline{Y}_j)^T$$

Thuật toán k -Means




Figure 6.4: Strengths and weaknesses of k -means

Thuật toán kernel k -Means

- Thuật toán k -means có thể được mở rộng để tìm các cụm với hình dạng bất kỳ bằng kỹ thuật kernel.
- Ý tưởng cơ bản là biến đổi ẩn dữ liệu sao cho các cụm với hình dạng bất kỳ được nối đến các cụm Euclid trong không gian mới.

Thuật toán k -Medoids

- Thuật toán k -Medoids mặc dù cũng dùng khái niệm đại diện và hàm mục tiêu, nhưng có cấu trúc thuật toán khác các phương pháp đã đề cập.
- Khác biệt chính của thuật toán này là các đại diện luôn được chọn từ các phần tử trong cơ sở dữ liệu.

Thuật toán k -Medoids

Algorithm *GenericMedoids*(Database: $\mathcal{D}$, Number of Representatives: k)

begin

Initialize representative set S by selecting from $\mathcal{D}$;

repeat

Create clusters $(\mathcal{C}_1 \dots \mathcal{C}_k)$ by assigning
each point in $\mathcal{D}$ to closest representative in S
using the distance function $Dist(\cdot, \cdot)$;

Determine a pair $\overline{X}_i \in \mathcal{D}$ and $\overline{Y}_j \in S$ such that
replacing $\overline{Y}_j \in S$ with $\overline{X}_i$ leads to the
greatest possible improvement in objective function;

Perform the exchange between $\overline{X}_i$ and $\overline{Y}_j$ only
if improvement is positive;

until no improvement in current iteration;

return $(\mathcal{C}_1 \dots \mathcal{C}_k)$;

end

Figure 6.5: Generic k -medoids algorithm with unspecified hill-climbing strategy

Các thuật toán dựa theo đại diện

Với các thuật toán dựa theo đại diện này, chúng ta có một số vấn đề đáng quan tâm:

- Các tiêu chí khởi động thuật toán.
- Chọn số nhóm.
- Ngoại lai.

Nội dung

- 1 Các thuật toán dựa theo đại diện
 - Thuật toán k -Means
 - Thuật toán kernel k -Means
 - Thuật toán k -Medoids
- 2 Các thuật toán gom cụm phân tầng
 - Phương pháp từ dưới lên (agglomerative/kết tụ)
 - Phương pháp từ trên xuống (divisive)
- 3 Các thuật toán dựa theo mô hình xác suất
- 4 Các thuật toán dựa theo lưới và dựa theo mật độ
 - Các thuật toán dựa theo lưới
 - Các thuật toán dựa theo mật độ
- 5 Các thuật toán dựa theo đồ thị

Các thuật toán gom cụm phân tầng

- Các thuật toán gom cụm phân tầng thường gom cụm dữ liệu với khoảng cách. Tuy nhiên, các hàm khoảng cách thường không bắt buộc phải có.
- Nhiều thuật toán phân tầng sử dụng các phương pháp gom cụm khác dưới dạng subroutine để xây dựng các tầng.
- Một lý do chính để sử dụng các phương pháp phân tầng là các độ mịn gom nhóm khác nhau cho chúng ta thêm các hiểu biết cụ thể theo ứng dụng.

Các thuật toán gom cụm phân tầng




Figure 6.6: Multigranularity insights from hierarchical clustering

Các thuật toán gom cụm phân tầng

Có 2 loại thuật toán phân tầng chính dựa vào cách cây phân tầng được xây dựng như thế nào.

- Các phương pháp từ dưới lên (agglomerative/kết tụ).
- Các phương pháp từ trên xuống (divisive).

Phương pháp từ dưới lên

Trong các phương pháp này, mỗi điểm dữ liệu bắt đầu với nhóm riêng (nhóm 1 điểm dữ liệu) và được tuần tự kết tụ thành các nhóm bậc cao hơn.

```
Algorithm AgglomerativeMerge(Data:  $\mathcal{D}$ )  
begin  
  Initialize  $n \times n$  distance matrix  $M$  using  $\mathcal{D}$ ;  
  repeat  
    Pick closest pair of clusters  $i$  and  $j$  using  $M$ ;  
    Merge clusters  $i$  and  $j$ ;  
    Delete rows/columns  $i$  and  $j$  from  $M$  and create  
      a new row and column for newly merged cluster;  
    Update the entries of new row and column of  $M$ ;  
  until termination criterion;  
  return current merged cluster set;  
end
```

Figure 6.7: Generic agglomerative merging algorithm with unspecified merging criterion

Phương pháp từ dưới lên





Figure 6.8: Illustration of hierarchical clustering steps

Phương pháp từ dưới lên


Trong các phương pháp này, chúng ta có một số tiêu chí như sau cho việc gộp các nhóm trong mỗi bước của thuật toán:

- Best (single) linkage.
- Worst (complete) linkage.
- Group-average linkage.
- Closest centroid.
- Các tiêu chí dựa theo phương sai.
- Phương pháp Ward.

Phương pháp từ dưới lên



(a) Good case with no noise



(b) Bad case with noise

Figure 6.9: Good and bad cases for single-linkage clustering

Phương pháp từ trên xuống

- Các phương pháp phân tầng từ trên xuống có thể được xem là các thuật toán meta mà có thể dùng subroutine là hầu hết các thuật toán gom cụm.
- Với cách tiếp cận từ trên xuống, chúng ta có thể có kiểm soát tốt hơn trên cấu trúc cây phân tầng.

Phương pháp từ trên xuống

Algorithm *GenericTopDownClustering*(Data: $\mathcal{D}$, Flat Algorithm: $\mathcal{A}$)
begin
 Initialize tree $\mathcal{T}$ to root containing $\mathcal{D}$;
 repeat
 Select a leaf node L in $\mathcal{T}$ based on pre-defined criterion;
 Use algorithm $\mathcal{A}$ to split L into $L_1 \dots L_k$;
 Add $L_1 \dots L_k$ as children of L in $\mathcal{T}$;
 until termination criterion;
end

Figure 6.10: Generic top-down meta-algorithm for clustering

Nội dung

- 1 Các thuật toán dựa theo đại diện
 - Thuật toán k -Means
 - Thuật toán kernel k -Means
 - Thuật toán k -Medoids
- 2 Các thuật toán gom cụm phân tầng
 - Phương pháp từ dưới lên (agglomerative/kết tụ)
 - Phương pháp từ trên xuống (divisive)
- 3 Các thuật toán dựa theo mô hình xác suất
- 4 Các thuật toán dựa theo lưới và dựa theo mật độ
 - Các thuật toán dựa theo lưới
 - Các thuật toán dựa theo mật độ
- 5 Các thuật toán dựa theo đồ thị

Các thuật toán dựa theo mô hình xác suất

- Các thuật toán như chúng ta đã tìm hiểu mà mỗi điểm dữ liệu được gom xác định gán vào một cụm cụ thể gọi là **hard clustering algorithm**.
- Trong khi đó, các thuật toán dựa theo mô hình xác suất là các **soft clustering algorithm** mà mỗi điểm dữ liệu được gán xác suất với nhiều (có thể tất cả) nhóm.
- Kết quả của thuật toán soft có thể chuyển về kết quả hard bằng cách gán các điểm dữ liệu vào nhóm với xác suất cao nhất.

Các thuật toán dựa theo mô hình xác suất

The broad principle of a mixture-based *generative* model is to assume that the data was generated from a mixture of k distributions with probability distributions $\mathcal{G}_1 \dots \mathcal{G}_k$. Each distribution $\mathcal{G}_i$ represents a cluster and is also referred to as a *mixture component*. Each data point $\overline{X}_i$, where $i \in \{1 \dots n\}$, is generated by this mixture model as follows:


1. Select a mixture component with prior probability $\alpha_i = P(\mathcal{G}_i)$, where $i \in \{1 \dots k\}$. Assume that the r th one is selected.
2. Generate a data point from $\mathcal{G}_r$.

Nội dung

- 1 Các thuật toán dựa theo đại diện
 - Thuật toán k -Means
 - Thuật toán kernel k -Means
 - Thuật toán k -Medoids
- 2 Các thuật toán gom cụm phân tầng
 - Phương pháp từ dưới lên (agglomerative/kết tụ)
 - Phương pháp từ trên xuống (divisive)
- 3 Các thuật toán dựa theo mô hình xác suất
- 4 Các thuật toán dựa theo lưới và dựa theo mật độ
 - Các thuật toán dựa theo lưới
 - Các thuật toán dựa theo mật độ
- 5 Các thuật toán dựa theo đồ thị

Các thuật toán dựa theo lưới và dựa theo mật độ

- Một vấn đề quan trọng với các thuật toán dựa theo khoảng cách hoặc các phương pháp xác suất là hình dáng của các nhóm đã được quy định ngầm với hàm khoảng cách hoặc phân phối xác suất.
- Đặc tính này sẽ không phù hợp với một số ứng dụng cần các nhóm có hình dạng bất kì.



(a) Arbitrarily-shaped clusters


Các thuật toán dựa theo lưới và dựa theo mật độ

- Với các tình huống thế này thì các phương pháp dựa theo mật độ rất hữu ích.
- Ý tưởng chính của phương pháp này là xác định các vùng dày đặc (mật độ cao) trong dữ liệu. Các vùng này sẽ là các “khối xây dựng” cho các cụm với hình dáng bất kỳ.
- Tùy thuộc vào việc lựa chọn các “khối xây dựng” mà chúng ta có các biến thể.


Các thuật toán dựa theo lưới

- Với các phương pháp này, dữ liệu được rời rạc hóa thành một số các khoảng (thường là cùng chiều rộng).
- Các hypercube từ việc rời rạc hóa này chính là các “khối xây dựng” cho thuật toán.
- Ở đây chúng ta có một threshold mật độ được dùng để xác định xem tập con nào của các hypercube này dày đặc (có mật độ cao).

Các thuật toán dựa theo lưới



(a) Data points and grid



(b) Agglomerating adjacent grids

Figure 6.13: Agglomerating adjacent grids

Algorithm *GenericGrid*(Data: $\mathcal{D}$, Ranges: p , Density: τ)
begin
 Discretize each dimension of data $\mathcal{D}$ into p ranges;
 Determine dense grid cells at density level τ ;
 Create graph in which dense grids are connected if they are adjacent;
 Determine connected components of graph;
 return points in each connected component as a cluster;
end

Figure 6.12: Generic grid-based algorithm

- The *DBSCAN* approach works on a very similar principle as grid-based methods. However, unlike grid-based methods, the density characteristics of data points are used to merge them into clusters. Therefore, the individual data points *in dense regions* are used as building blocks after classifying them on the basis of their density.
- The density of a data point is defined by the number of points that lie within a radius *Eps* of that point (including the point itself). The densities of these spherical regions are used to classify the data points into *core*, *border*, or *noise* points:
 - *Core point*: A data point contains at least $\mathcal{T}$ data points.
 - *Border point*: A data point contains less than $\mathcal{T}$ points, but it also contains at least one core point within a radius *Eps*.
 - *Noise point*: A data point that is neither a core point nor a border point.




Figure 6.16: Examples of core, border, and noise points

Algorithm *DBSCAN*(Data: $\mathcal{D}$, Radius: Eps , Density: τ)
begin
 Determine core, border and noise points of $\mathcal{D}$ at level (Eps, τ) ;
 Create graph in which core points are connected
 if they are within Eps of one another;
 Determine connected components in graph;
 Assign each border point to connected component
 with which it is best connected;
 return points in each connected component as a cluster;
end

Figure 6.15: Basic *DBSCAN* algorithm

The *DENCLUE* algorithm is based on firm statistical foundations that are rooted in kernel-density estimation. Kernel-density estimation can be used to create a smooth profile of the density distribution. In kernel-density estimation, the density $f(\bar{X})$ at coordinate $\bar{X}$ is defined as a sum of the influence (kernel) functions $K(\cdot)$ over the n different data points in the database $\mathcal{D}$:

$$f(\bar{X}) = \frac{1}{n} \sum_{i=1}^n K(\bar{X} - \bar{X}_i).$$

A wide variety of kernel functions may be used, and a common choice is the Gaussian kernel. For a d -dimensional data set, the Gaussian kernel is defined as follows:

$$K(\bar{X} - \bar{X}_i) = \left(\frac{1}{h\sqrt{2\pi}} \right)^d e^{-\frac{\|\bar{X} - \bar{X}_i\|^2}{2 \cdot h^2}}.$$




Figure 6.18: Density-based profile with lower density threshold




Figure 6.19: Density-based profile with higher density threshold

Nội dung

- 1 Các thuật toán dựa theo đại diện
 - Thuật toán k -Means
 - Thuật toán kernel k -Means
 - Thuật toán k -Medoids
- 2 Các thuật toán gom cụm phân tầng
 - Phương pháp từ dưới lên (agglomerative/kết tụ)
 - Phương pháp từ trên xuống (divisive)
- 3 Các thuật toán dựa theo mô hình xác suất
- 4 Các thuật toán dựa theo lưới và dựa theo mật độ
 - Các thuật toán dựa theo lưới
 - Các thuật toán dựa theo mật độ
- 5 Các thuật toán dựa theo đồ thị

Các thuật toán dựa theo đồ thị

- Các thuật toán dựa theo đồ thị cung cấp một meta-framework chung mà trong đó gần như tất cả kiểu dữ liệu đều có thể được gom nhóm.
- Ý quan trọng cần để ý ở đây là gần như tất cả kiểu dữ liệu đều có thể được biến đổi thành đồ thị tương đồng để thực hiện phân tích.

The notion of pairwise similarity is defined with the use of a *neighborhood graph*. Consider a set of data objects $\mathcal{O} = \{O_1, \dots, O_n\}$, on which a neighborhood graph can be defined. Note that these objects can be of any type, such as time series or discrete sequences. The main constraint is that it should be possible to define a distance function on these objects.

Các thuật toán dựa theo đồ thị

The neighborhood graph is constructed as follows:

1. A single node is defined for each object in $\mathcal{O}$. This is defined by the node set N , containing n nodes, where the node i corresponds to the object O_i .
2. An edge exists between O_i and O_j , if the distance $d(O_i, O_j)$ is less than a particular threshold ϵ . A better approach is to compute the k -nearest neighbors of both O_i and O_j , and add an edge when either one is a k -nearest neighbor of the other.

$$w_{ij} = e^{-d(O_i, O_j)^2 / t^2}.$$

where t is a parameter.

3. (Optional step) This step can be helpful for reducing the impact of local density variations. Note that the quantity $\deg(i) = \sum_{r=1}^n w_{ir}$ can be viewed as a proxy for the local kernel-density estimate near object O_i . Each edge weight w_{ij} is normalized by dividing it with $\sqrt{\deg(i) \cdot \deg(j)}$. Such an approach ensures that the clustering is performed after normalization of the similarity values with local densities. This step is not essential when algorithms such as normalized spectral clustering are used for finally clustering nodes in the neighborhood graph. This is because spectral clustering methods perform a similar normalization under the covers.

Các thuật toán dựa theo đồ thị

Sau khi có được đồ thị từ quá trình xây dựng như trước, chúng ta có thể dùng các thuật toán gom nhóm thích hợp cho các đồ thị này.

```
Algorithm GraphMetaFramework(Data:  $\mathcal{D}$ )  
begin  
    Construct the neighborhood graph  $G$  on  $\mathcal{D}$ ;  
    Determine clusters (communities) on the nodes in  $G$ ;  
    return clusters corresponding to the node partitions;  
end
```

Figure 6.20: Generic graph-based meta-algorithm

Các thuật toán dựa theo đồ thị

Một tính chất thú vị của các thuật toán dựa theo đồ thị là các nhóm với hình dạng bất kì có thể được tìm ra do các đồ thị này chứa thông tin về khoảng cách địa phương.




Figure 6.21: The merits of the k -nearest neighbor graph for handling clusters of varying shape and density

Thank You!