

KHAI PHÁ DỮ LIỆU

Tuần 09

PGS. TS. Nguyễn Thanh Bình

Khoa Toán - Tin học, Trường Đại học Khoa học Tự nhiên
Đại học Quốc gia TP. Hồ Chí Minh

1 Khai phá mẫu liên hệ (tiếp theo)

- Phân tách ma trận không âm
- Đánh giá gom cụm

2 Phân tích ngoại lai

- Phân tích ngoại lai
- Phân tích giá trị cực hạn
- Mô hình xác suất
- Gom nhóm cho việc phát hiện ngoại lai
- Phát hiện ngoại lai theo khoảng cách
- Các phương pháp theo mật độ
- Các mô hình theo lý thuyết thông tin
- Xác thực ngoại lai

1 Khai phá mẫu liên hệ (tiếp theo)

- Phân tách ma trận không âm
- Đánh giá gom cụm

2 Phân tích ngoại lai

- Phân tích ngoại lai
- Phân tích giá trị cực hạn
- Mô hình xác suất
- Gom nhóm cho việc phát hiện ngoại lai
- Phát hiện ngoại lai theo khoảng cách
- Các phương pháp theo mật độ
- Các mô hình theo lý thuyết thông tin
- Xác thực ngoại lai

Nonnegative matrix factorization (NMF) is a dimensionality reduction method that is tailored to clustering. In other words, it embeds the data into a latent space that makes it more amenable to clustering. This approach is suitable for data matrices that are *nonnegative* and *sparse*. For example, the $n \times d$ document-term matrix in text applications always contains non-negative entries. Furthermore, because most word frequencies are zero, this matrix is also sparse.

Phân tách ma trận không âm

Nonnegative matrix factorization creates a new *basis system* for data representation, as in all dimensionality reduction methods. However, a distinguishing feature of *NMF* compared to many other dimensionality reduction methods is that the basis system does not necessarily contain orthonormal vectors. Furthermore, the basis system of vectors and the coordinates of the data records in this system are non-negative. The non-negativity of the representation is highly interpretable and well-suited for clustering. Therefore, non-negative matrix factorization is one of the dimensionality reduction methods that serves the dual purpose of enabling data clustering.

Phân tách ma trận không âm

- Với ma trận dữ liệu D kích thước $n \times d$, ở đây chúng ta sẽ tìm 2 ma trận $U (n \times k)$ và $V (d \times k)$ không âm sao cho hàm mục tiêu sau đạt cực tiểu.

$$J = \frac{1}{2} \|D - UV^T\|^2$$

- Bài toán tối ưu này có thể được dùng cho mục đích phân rã sau

$$D \approx UV^T$$

Phân tích ma trận không âm




Figure 6.22: An example of non-negative matrix factorization

Phân tích ma trận không âm




Figure 6.23: The interpretable matrix decomposition of NMF

Phân tách ma trận không âm

One interesting observation about the matrix factorization technique is that it can also be used to determine word-clusters instead of document clusters. Just as the columns of V provide a basis that can be used to discover document clusters, one can use the columns of U to discover a basis that corresponds to word clusters. Thus, this approach provides complementary insights into spaces where the dimensionality is very large.

Phân tách ma trận không âm

- Với phân rã SVD , ta có:

$$D \approx Q_k \sum_k P_k^T$$

- So với phân tách ma trận không âm (NMF) $U (n \times k)$ và $V (d \times k)$

$$D \approx UV^T$$

- Chúng ta có ma trận $Q_k \sum_k (n \times k)$ tương ứng với $U (n \times k)$ và $P_k (d \times k)$ tương ứng với $V (n \times k)$.
- Khác biệt quan trọng nhất ở đây là SVD có ràng buộc về tính trực giao với các vector cơ sở thay vì ràng buộc không âm của NMF .

Phân tách ma trận không âm

Ngoài ra, các biến thể phân tách ma trận khác nhau cũng cho các lợi ích ứng dụng khác nhau:

- The latent factors in *NMF* are more easily interpretable for clustering applications, because of non-negative. For example, in application domains such as text clustering, each of the k columns in U and V can be associated with document clusters and word clusters, respectively. The magnitudes of the non-negative (transformed) coordinates reflect which concepts are strongly expressed in a document. This "additive parts" representation of *NMF* is highly interpretable, especially in domains such as text, in which the features have semantic meaning. This is not possible with *SVD* in which transformed coordinate values and basis vector components may be negative. This is also the reason that *NMF* transformations are more useful than those of *SVD* for clustering. Similarly, the probabilistic forms of non-negative matrix factorization, such as *PLSA*, are also used commonly for clustering.

Phân tách ma trận không âm

Ngoài ra, các biến thể phân tách ma trận khác nhau cũng cho các lợi ích ứng dụng khác nhau:

- Unlike *SVD*, the k latent factors of *NMF* are not orthogonal to one another. This is a disadvantage of *NMF* because orthogonality of the axis-system allows intuitive interpretations of the data transformation as an axis-rotation. It is easy to project *out-of-sample* data points (i.e., data points not included in D) on an orthonormal basis system. Furthermore, distance computations between transformed data points are more meaningful in *SVD*.

Phân tách ma trận không âm

Ngoài ra, các biến thể phân tách ma trận khác nhau cũng cho các lợi ích ứng dụng khác nhau:

- The addition of a constraint, such as non-negativity, to any optimization problem usually reduces the quality of the solution found. However, the addition of orthogonality constraints, as in *SVD*, do not affect the *theoretical* global optimum of the *unconstrained* matrix factorization formulation. Therefore, *SVD* provides better rank- k approximations than *NMF*. Furthermore, it is much easier *in practice* to determine the global optimum of *SVD*, as compared to unconstrained matrix factorization for matrices that are completely specified. Thus, *SVD* provides one of the alternate global optima of unconstrained matrix factorization, which is computationally easy to determine.
- *SVD* is generally hard to implement for incomplete data matrices as compared to many other variations of matrix factorization. This is relevant in recommender systems where rating matrices are incomplete.

Đánh giá gom cụm

- Với các cụm có được sau quá trình gom cụm, chúng ta cũng quan tâm việc đánh giá chất lượng thông qua việc đánh giá gom cụm.
- Khi chúng ta không có các dữ liệu đánh nhãn do đặc thù không giám sát của bài toán gom cụm, chúng ta cần sử dụng các tiêu chí đánh giá trong.
- Trong trường hợp chúng ta có dữ liệu đánh nhãn, chúng ta có thể sử dụng các tiêu chí đánh giá ngoài.
- Cả 2 hướng này đều có các hạn chế quan trọng đáng lưu ý.

Một số tiêu chí đánh giá quan trọng

Sum of square distances to centroids: In this case, the centroids of the different clusters are determined, and the sum of squared (SSQ) distances are reported as the corresponding objective function. Smaller values of this measure are indicative of better cluster quality. This measure is obviously more optimized to distance-based algorithms, such as *k*-means, as opposed to a density-based method, such as *DBSCAN*. Another problem with SSQ is that the absolute distances provide no meaningful information to the user about the quality of the underlying clusters.

Một số tiêu chí đánh giá quan trọng

Intracluster to intercluster distance ratio: This measure is more detailed than the SSQ measure. The idea is to sample r pairs of data points from the underlying data. Of these, let P be the set of pairs that belong to the same cluster found by the algorithm. The remaining pairs are denoted by set Q . The average intercluster distance and intracluster distance are defined as follows:

$$Intra = \sum_{(\overline{X}_i, \overline{X}_j) \in P} dist(\overline{X}_i, \overline{X}_j) / |P|$$

$$Inter = \sum_{(\overline{X}_i, \overline{X}_j) \in Q} dist(\overline{X}_i, \overline{X}_j) / |Q|$$

Then the ratio of the average intracluster distance to the intercluster distance is given by $Intra/Inter$. Small values of this measure indicate better clustering behavior.

Một số tiêu chí đánh giá quan trọng

Silhouette coefficient: Let $Davg_i^{in}$ be the average distance of $\bar{X}_i$ to data points *within* the cluster of $\bar{X}_i$. The average distance of data point $\bar{X}_i$ to the points in each cluster (other than its own) is also computed. Let $Dmin_i^{out}$ represent the minimum of these (average) distances, over the other clusters. Then, the silhouette coefficient S_i *specific to the i th object*, is as follows:

$$S_i = \frac{Dmin_i^{out} - Davg_i^{in}}{\max\{Dmin_i^{out}, Davg_i^{in}\}}$$

The overall silhouette coefficient is the average of the data point-specific coefficients. The silhouette coefficient will be drawn from the range $(-1, 1)$. Large positive values indicate highly separated clustering, and negative values are indicative of some level of “mixing” of data points from different clusters. This is because $Dmin_i^{out}$ will be less than $Davg_i^{in}$ only in cases where data point $\bar{X}_i$ is closer to at least one other cluster than its own cluster. One advantage of this coefficient is that the absolute values provide a good intuitive feel of the quality of the clustering.

Một số tiêu chí đánh giá quan trọng

Probabilistic measure: In this case, the goal is to use a mixture model to estimate the quality of a particular clustering. The centroid of each mixture component is assumed to be the centroid of each discovered cluster, and the other parameters of each component (such as the covariance matrix) are computed from the discovered clustering using a method similar to the M-step of EM algorithms. The overall loglikelihood of the measure is reported. Such a measure is useful when it is known from domain-specific knowledge that the clusters ought to have a specific shape, as is suggested by the distribution of each component in the mixture.

Đánh giá gom cụm

- Với trường hợp chúng ta có dữ liệu đánh nhãn để sử dụng các tiêu chí đánh giá ngoài (VD: trong trường hợp sử dụng synthetic dataset).
- Một cách tiếp cận ở đây là sử dụng ý tưởng về confusion matrix.

Cluster Indices	1	2	3	4
1	97	0	2	1
2	5	191	1	3
3	4	3	87	6
4	0	0	5	195

Figure 6.25: Confusion matrix for a clustering of good quality

Cluster Indices	1	2	3	4
1	33	30	17	20
2	51	101	24	24
3	24	23	31	22
4	46	40	44	70

Figure 6.26: Confusion matrix for a clustering of poor quality

1 Khai phá mẫu liên hệ (tiếp theo)

- Phân tách ma trận không âm
- Đánh giá gom cụm

2 Phân tích ngoại lai

- Phân tích ngoại lai
- Phân tích giá trị cực hạn
- Mô hình xác suất
- Gom nhóm cho việc phát hiện ngoại lai
- Phát hiện ngoại lai theo khoảng cách
- Các phương pháp theo mật độ
- Các mô hình theo lý thuyết thông tin
- Xác thực ngoại lai

- Một ngoại lai là một điểm dữ liệu rất khác biệt với phần lớn các dữ liệu còn lại.
- Nếu như việc gom nhóm xác định các nhóm điểm dữ liệu giống nhau thì các ngoại lai là các điểm dữ liệu riêng lẻ khác biệt với các điểm còn lại.

Một số ứng dụng của việc phát hiện ngoại lai:

- Làm sạch dữ liệu.
- Phát hiện gian lận thẻ tín dụng.
- Phát hiện xâm nhập mạng.

Phân tích ngoại lai

Phần lớn các thuật toán phát hiện ngoại lai cho output thuộc một trong hai loại.

- Điểm ngoại lai giá trị thực.
- Nhãn nhị phân.

Một số mô hình chính cho phân tích ngoại lai như sau:

- Điểm cực hạn.
- Mô hình gom nhóm.
- Mô hình theo khoảng cách.
- Mô hình theo mật độ.
- Mô hình xác suất.
- Mô hình lý thuyết thông tin.

Phân tích giá trị cực hạn

- Phân tích giá trị cực hạn là một dạng phân tích ngoại lai với các điểm dữ liệu ở vùng ngoài của dữ liệu.
- Lưu ý rằng các điểm cực hạn là một dạng ngoại lai cụ thể nhưng không phải ngoại lai nào cũng là điểm cực hạn.

Phân tích giá trị cực hạn





Figure 8.1: Multivariate extreme values


Phân tích giá trị cực hạn đơn biến

- Phân tích giá trị cực hạn đơn biến liên quan mật thiết đến các kiểm định độ tin cậy đuôi thống kê (statistical tail confidence test).
- Ở đây, đuôi thống kê là các vùng với mật độ phân phối thấp hơn một ngưỡng nào đó.
- Các phương pháp này xác định tỉ lệ các đối tượng được kì vọng là cực hạn dựa vào các giả thiết về phân phối.

Phân tích giá trị cực hạn đơn biến



(a) Symmetric distribution




(b) Asymmetric distribution


Figure 8.2: Tails of a symmetric and asymmetric distribution

Phân tích giá trị cực hạn đa biến

Tương tự với trong trường hợp đơn biến, các đuôi thống kê cũng có thể được định nghĩa một cách tương tự.



(a) Multivariate extreme values



(b) Multivariate extreme values
(probabilistic interpretation)

Figure 8.3: Multivariate extreme values

Các phương pháp theo chiều sâu

- Các phương pháp theo chiều sâu dựa trên nguyên lý chung là bao lồi của một tập các điểm dữ liệu thể hiện các cực tối ưu Pareto của tập đó.
- Các thuật toán này hoạt động theo các bước lặp mà khi ở bước k , tất cả các điểm ở góc của bao lồi được loại bỏ.
- Các chỉ số của bước lặp cũng cho ta một điểm ngoại lai với số nhỏ hơn thể hiện khả năng ngoại lai cao hơn.

Các phương pháp theo chiều sâu




Figure 8.5: Depth-based outlier detection

Các phương pháp theo chiều sâu

Algorithm *FindDepthOutliers*(Data Set: $\mathcal{D}$, Score Threshold: r)
begin
 $k = 1$;
 repeat
 Find set S of corners of convex hull of $\mathcal{D}$;
 Assign depth k to points in S ;
 $\mathcal{D} = \mathcal{D} - S$;
 $k = k + 1$;
 until ($\mathcal{D}$ is empty);
 Report points with depth at most r as outliers;
end

Figure 8.4: Depth-based methods

Mô hình xác suất

- Các mô hình xác suất dựa trên sự tổng quát hóa của các phương pháp phân tích giá trị cực hạn đa biến.
- Cụ thể, phương pháp phân tích giá trị cực hạn đa biến theo khoảng cách Mahalanobis có thể được xem là một mô hình Gaussian mixture với một thành phần mixture đơn.
- Khi tổng quát hoá mô hình này với nhiều thành phần mixture, chúng ta có thể xác định các ngoại lai.

Mô hình xác suất




Figure 8.6: Likelihood fit values versus outlier scores

Gom nhóm cho việc phát hiện ngoại lai

- Nếu việc gom nhóm tìm các cụm dữ liệu dày đặc thì việc phân tích ngoại lai tìm các điểm xa những cụm này.
- Một cách nhìn đơn giản ở đây là mỗi điểm dữ liệu nếu không nằm trong một cụm nào khi gom nhóm thì sẽ được xem là ngoại lai.
- Các thuật toán gom nhóm thường có lựa chọn để loại bỏ ngoại lai. Tuy nhiên, do các thuật toán này không được tối ưu để phát hiện ngoại lai nên sử dụng như vậy không thích hợp.
- Một cách đơn giản để xác định điểm số ngoại lai của một điểm dữ liệu là trước hết gom nhóm tập dữ liệu và sau đó dùng khoảng cách của điểm dữ liệu đó đến tâm của cụm gần nhất.

Gom nhóm cho việc phát hiện ngoại lai




Figure 8.7: Small isolated groups of anomalies

Phát hiện ngoại lai theo khoảng cách

- Do ngoại lai là các điểm dữ liệu ở xa các vùng dữ liệu dày đặc, chúng ta cũng có thể sử dụng khoảng cách của một điểm đến k -th nearest neighbor để tính điểm ngoại lai của điểm đó.
- Ngoài ra còn một số biến thể khác như sử dụng khoảng cách trung bình đến k -nearest neighbor.
- Các phương pháp theo khoảng cách này thường cho độ mịn cao hơn các phương pháp gom cụm với nhược điểm là độ phức tạp tính toán cao hơn.

Phát hiện ngoại lai theo khoảng cách

Do vấn đề về độ phức tạp tính toán này, chúng ta có một số phương pháp để tăng tốc độ tính toán.

- **Index structures:** Index structures can be used to determine k th nearest neighbor distances efficiently. This is, however, not an option, if the data is high dimensional. In such cases, the effectiveness of index structures tends to degrade.
- **Pruning tricks:** In most applications, the outlier scores of all the data points are not required. It may suffice to return binary labels for the top- r outliers, together with their scores. The outlier scores of the remaining data points are irrelevant. In such cases, it may be possible to terminate a k -nearest neighbor sequential scan for an outlier candidate when its current *upper bound estimate* on the k -nearest neighbor distance value falls below the r th best outlier score found so far. This is because such a candidate is guaranteed to be not among the top- r outliers.

Các phương pháp cắt xén

- Các phương pháp này chỉ được dùng khi các ngoại lai top- r cần được trả về và không quan tâm đến điểm của các ngoại lai còn lại.
- Do đó, các phương pháp cắt xén chỉ thích hợp cho dự đoán nhị phân cho ngoại lai.

Các phương pháp cắt xén

Các phương pháp cắt xén có 2 hướng tiếp cận:

- Sử dụng các phương pháp lấy mẫu.
- Sử dụng kỹ thuật kết thúc sớm với các vòng lặp chồng nhau.

Các phương pháp điều chỉnh khoảng cách cục bộ

- (Chương 3) Các độ đo thông thường như khoảng cách Euclid không nhất thiết thể hiện khoảng cách nội tại giữa các điểm dữ liệu khi mật độ và hình dạng của các cụm thay đổi tại mỗi địa phương.
- Một trong các phương pháp sử dụng mật độ dữ liệu thay đổi là phương pháp Local Outlier Factor (LOF).

Các phương pháp điều chỉnh khoảng cách cục bộ




Figure 8.8: Impact of local variations in data distribution on distance-based outlier detection

- Cách tiếp cận này điều chỉnh với các thay đổi cục bộ về mật độ cụm bằng cách chuẩn hóa khoảng cách bằng khoảng cách cụ thể theo điểm trung bình trong một cục bộ dữ liệu.
- Bước chuẩn hóa này có vai trò quan trọng trong việc xử lý khó khăn như tình huống trong hình 8.8a

Instance-Specific Mahalanobis Distance

- Cách tiếp cận này được thiết kế để điều chỉnh theo hình dạng thay đổi của phân phối tại cục bộ của một điểm dữ liệu cụ thể, như hình 8.8b.
- Ở đây, khoảng cách Mahalanobis liên quan trực tiếp đến hình dạng của phân phối dữ liệu, nhưng thường là theo cách hiểu toàn cục.
- Tuy nhiên, chúng ta cũng có thể sử dụng khoảng cách Mahalanobis cục bộ.

Các phương pháp theo mật độ

- Các phương pháp phát hiện ngoại lai theo mật độ được dựa trên các nguyên lý tương tự như các phương pháp gom nhóm theo mật độ.
- Ý tưởng chính là xác định các vùng thưa trong dữ liệu để chọn ra các ngoại lai.
- Ở đây chúng ta có các phương pháp dựa theo histogram, theo lưới hoặc theo mật độ kernel.
- Các phương pháp này không phổ biến lắm do khó điều chỉnh theo các biến động mật độ ở các cục bộ dữ liệu khác nhau.

Các kỹ thuật theo histogram và theo lưới

- Các histogram có thể được dễ dàng xây dựng cho dữ liệu đơn biến với rất nhiều ứng dụng.
- Với các kỹ thuật này, dữ liệu được chia thành các ngăn và tần suất của mỗi ngăn được ước lượng.
- Các điểm dữ liệu nằm trong các ngăn với tần suất rất thấp được xác định là ngoại lai.

Các kỹ thuật theo histogram và theo lưới

- Với dữ liệu đa biến, chúng ta có một cách tổng hóa của histogram là lưới.
- Mỗi chiều được chia thành các khoảng cùng độ dài.
- Các điểm dữ liệu nằm trong các vùng lưới có mật độ thấp được xác định là ngoại lai.

Ước lượng mật độ kernel

- Các phương pháp này giống với các kĩ thuật histogram theo cách xây dựng profile mật độ.
- Tuy nhiên, một khác biệt lớn là chúng ta có các profile mật độ mịn hơn. Cụ thể, chúng ta có một ước lượng liên tục cho mỗi điểm.
- Mỗi hàm kernel đi kèm với một độ dài kernel h xác định độ mịn từ hàm.

Ước lượng mật độ kernel

Kernel density estimation methods are similar to histogram techniques in terms of building density profiles, though the major difference is that a smoother version of the density profile is constructed. In kernel density estimation, a continuous estimate of the density is generated at a given point. The value of the density at a given point is estimated as the sum of the smoothed values of kernel functions $K_h(.)$ associated with each point in the data set. Each kernel function is associated with a kernel width h that determines the level of smoothing created by the function. The kernel estimation $f(\bar{X})$ based on n data points of dimensionality d , and kernel function $K_h(.)$ is defined as follows:

$$f(\bar{X}) = \frac{1}{n} \cdot \sum_{i=1}^n K_h(\bar{X} - \bar{X}_i)$$

Thus, each discrete point $\bar{X}_i$ in the data set is replaced by a continuous function $K_h(.)$ that peaks at $\bar{X}_i$ and has a variance determined by the smoothing parameter h . An example of such a distribution is the Gaussian kernel with width h .

$$K_h(\bar{X} - \bar{X}_i) = \left(\frac{1}{\sqrt{2\pi} \cdot h}\right)^d \cdot e^{-||\bar{X} - \bar{X}_i||^2 / (2h)^2}$$

Các mô hình theo lý thuyết thông tin

- Các mô hình theo lý thuyết thông tin có thể được xem là gần như tương đương với các mô hình bình thường.
- Với một khác biệt chính là các điểm số ngoại lai được xác định bởi kích thước mô hình cho một độ lệch cố định thay vì được xác định bởi độ lệch cho một mô hình cố định.

Các mô hình theo lý thuyết thông tin

Cụ thể, chúng ta có các so sánh như sau:

- The probabilistic model of Sect. 8.3 models the normal patterns in terms of generative model parameters such as the mixture means and covariance matrices. The space required by the model is defined by its complexity (e.g., number of mixture components), and the deviation corresponds to the probabilistic fit. In an informationtheoretic version of the model, the complementary approach is to examine the size of the model required to achieve a fixed level of fit.

Các mô hình theo lý thuyết thông tin

Cụ thể, chúng ta có các so sánh như sau:

- A clustering or density-based summarization model describes a data set in terms of cluster descriptions, histograms or other summarized representations. The granularity of these representations (number of cluster centroids, or histogram bins) controls the space, whereas the error in approximating the data point with a central element of the cluster (bin) defines the deviation. In conventional models, the size of the model (number of bins or clusters) is fixed, whereas in the information-theoretic version, the maximum allowed deviation is fixed, and the required model size is reported as the outlier score.

Các mô hình theo lý thuyết thông tin

Cụ thể, chúng ta có các so sánh như sau:

- A frequent pattern mining model describes the data in terms of an underlying codebook of frequent patterns. The larger the size of the code-book (by using frequent patterns of lower support), the more accurately the data can be described. These models are particularly popular, and some pointers are provided in the bibliographic notes.

Xác thực ngoại lai

- Như trường hợp các mô hình gom nhóm, chúng ta muốn xác định tính xác thực của các ngoại lai phát hiện được bằng mỗi thuật toán.
- Mặc dù việc gom nhóm và phát hiện ngoại lai có quan hệ hỗ trợ, các độ đo tính xác thực cho ngoại lai không thể được thiết kế dễ dàng theo cách hỗ trợ.

Các thử thách về phương pháp luận

- Tương tự như các phương pháp gom cụm, phân tích ngoại lai thường có dạng bài toán không được giám sát.
- Do tính không giám sát này mà chúng ta thường thiếu các tiêu chí ngoài để xác thực kết quả.
- Từ đây chúng ta muốn tìm các tiêu chí trong cho việc này.
- Tuy nhiên, các khuyết điểm của các tiêu chí trong trong phân tích ngoại lai còn nặng hơn trong gom nhóm và do đó hiếm khi được sử dụng.

Receiver Operating Characteristic

- Các thuật toán phát hiện ngoại lai thường được đánh giá với các độ đo ngoài khi chúng ta có nhãn các ngoại lai từ dữ liệu synthetic hoặc các trường hợp hiếm có từ dữ liệu thật.
- Các nhãn này được so sánh một cách hệ thống với điểm số ngoại lai từ model.

Receiver Operating Characteristic

- Với các mô hình phát hiện ngoại lai, một ngưỡng nào đó thường được dùng với điểm số ngoại lai để xác định nhãn nhị phân, và việc chọn ngưỡng này ảnh hưởng đến false positive và false negative.
- Để chọn lựa thuật toán với trade off thích hợp, chúng ta có thể sử dụng các trade-off curve tạo ra từ một số phương pháp như Receiver Operating Characteristic (ROC) curve.

Receiver Operating Characteristic

Lưu ý:

A common mistake in benchmarking outlier analysis applications is that the area under the ROC curve is used repeatedly to tune the parameters of the outlier analysis algorithm. Note that such an approach implicitly uses the ground-truth labels for model construction, and it is, therefore, no longer an unsupervised algorithm. For problems such as clustering and outlier detection, it is not acceptable to use external labels in any way to tune the algorithm. In the particular case of outlier analysis, the accuracy can be drastically overestimated with such a tuning approach because the relative scores of a small number of outlier points have a very large influence on the ROC curve.

Thank You!